VINIX 7 AURUM
2026

DATA ANALYST: TUGAS MODUL 4

KELOMPOK 36

- Dorra Ria Salsabila Khoirunnisa
- Muhammad Syahreza
- Wisnu Darmawan
- Yuliana Indah Wulandary

Ringkasan

Fokus analisis: profil statistik, eksplorasi visual, tiga insight beserta hipotesis, rekomendasi awal untuk intervensi akademik, dan evaluasi model prediksi sebagai analisis tambahan.

> Dataset berisi **10.000 catatan siswa** dengan 6 variabel dan tanpa nilai kosong. **Previous Scores** memiliki hubungan terkuat dengan Performance Index (korelasi **0,915**), disusul **Hours Studied** (0,374). Dalam setiap kelompok nilai awal, rata-rata Performance Index naik seiring jam belajar. Namun, siswa dengan nilai awal 40-59 yang belajar 7-9 jam (rata-rata **43,67**) masih di bawah siswa nilai awal 60-79 yang belajar 1-3 jam (**46,57**). Model Linear Regression pada data uji menghasilkan R^2 **0,9884**. Seluruh temuan bersifat korelasional dan belum membuktikan hubungan sebab-akibat.

1. Dataset dan Persiapan

Analisis menggunakan berkas *Student_Performance.csv* dengan ukuran **10.000 baris x 6 kolom**. Empat kolom bertipe bilangan bulat, satu kolom bertipe desimal (Performance Index), dan satu kolom kategorikal (Extracurricular Activities). Pengolahan dilakukan dengan Python (pandas, NumPy, matplotlib, seaborn, dan scikit-learn).

Tabel 1. Lima baris pertama dataset

Hours Studied	Previous Scores	Extracurricular Activities	Sleep Hours	Sample Question Papers Practiced	Performance Index
7	99	Yes	9	1	91,0
4	82	No	4	2	65,0
8	51	Yes	7	2	45,0
5	52	Yes	5	2	36,0
7	75	No	8	5	66,0

2. Struktur dan Kualitas Data

Pemeriksaan awal mencakup ukuran dataset dan tipe data, nilai kosong dan baris identik, serta kesesuaian rentang nilai setiap variabel.

Hasil Pemeriksaan

Dataset memuat **10.000 catatan tanpa nilai kosong**. Terdapat **127 baris identik (1,27%)**. Tanpa identitas siswa, baris identik belum dapat dipastikan sebagai kesalahan pencatatan.

Tabel 2. Validasi rentang nilai berdasarkan definisi fitur

Variabel	Rentang yang diharapkan	Status
Hours Studied	1 - 9	OK
Previous Scores	40 - 99	OK
Sleep Hours	4 - 9	OK
Sample Question Papers Practiced	0 - 9	OK
Performance Index	10 - 100	OK

Keputusan analisis:

- EDA menggunakan seluruh catatan yang tersedia.
- Baris identik belum dapat dipastikan sebagai kesalahan pencatatan tanpa identitas siswa.

- Pada evaluasi model, baris identik dihapus sebelum pembagian data latih dan uji untuk mengurangi peluang profil yang sama muncul di kedua kelompok.

3. Profil Statistik

Variabel numerik dirangkum dengan mean, median, modus, simpangan baku, minimum, dan maksimum. Variabel kategorikal dirangkum dengan jumlah kategori, modus, frekuensi, dan proporsi.

Tabel 3. Profil statistik variabel numerik

Variabel	Mean	Median	Modus	Std Dev	Min	Maks
Hours Studied	4,99	5,00	1	2,59	1	9
Previous Scores	69,45	69,00	54	17,34	40	99
Sleep Hours	6,53	7,00	8	1,70	4	9
Sample Question Papers Practiced	4,58	5,00	6	2,87	0	9
Performance Index	55,22	55,00	67	19,21	10	100

Tabel 4. Distribusi Extracurricular Activities

Kategori	Jumlah	Proporsi (%)
No	5.052	50,52
Yes	4.948	49,48

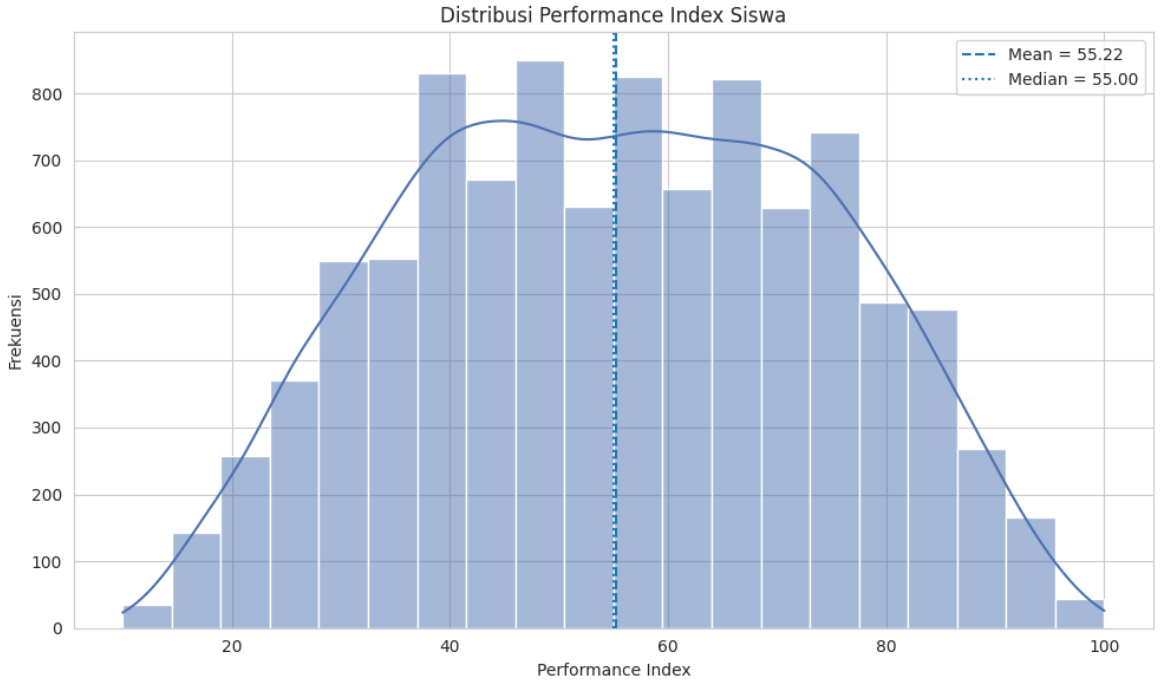
Ringkasan Statistik

- **Performance Index:** rata-rata 55,22, median 55,00, simpangan baku 19,21. Sebaran nilai antarsiswa cukup besar.
- **Previous Scores:** rata-rata 69,45. Hubungannya dengan Performance Index ditelaah pada analisis korelasi.
- **Kebiasaan belajar:** rata-rata Hours Studied 4,99 jam, Sleep Hours 6,53 jam, dan latihan soal 4,58. Hubungan masing-masing dengan target diperiksa pada bagian berikutnya.
- **Extracurricular Activities:** kategori Yes dan No memiliki jumlah yang hampir seimbang.

4. Eksplorasi Visual

4.1 Distribusi Performance Index

Pertanyaan: bagaimana sebaran nilai Performance Index?

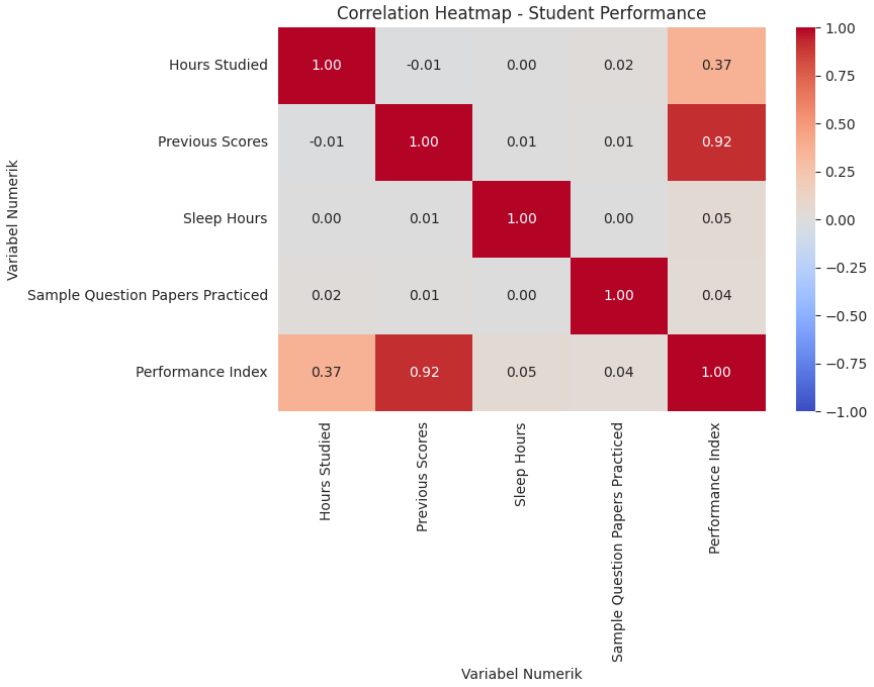


Gambar 1. Distribusi Performance Index siswa

Temuan: Performance Index berkisar dari **10 hingga 100**. Rata-rata **55,22** dan median **55** menunjukkan pusat distribusi yang relatif seimbang; simpangan baku **19,21** menunjukkan perbedaan antarsiswa yang cukup besar. Rata-rata saja belum mewakili seluruh variasi performa.

4.2 Korelasi Variabel Numerik

Pertanyaan: variabel numerik mana yang paling kuat berkaitan dengan Performance Index?



Gambar 2. Correlation heatmap variabel numerik

Tabel 5. Korelasi terhadap Performance Index

Variabel	Korelasi
Previous Scores	0,915
Hours Studied	0,374
Sleep Hours	0,048
Sample Question Papers Practiced	0,043

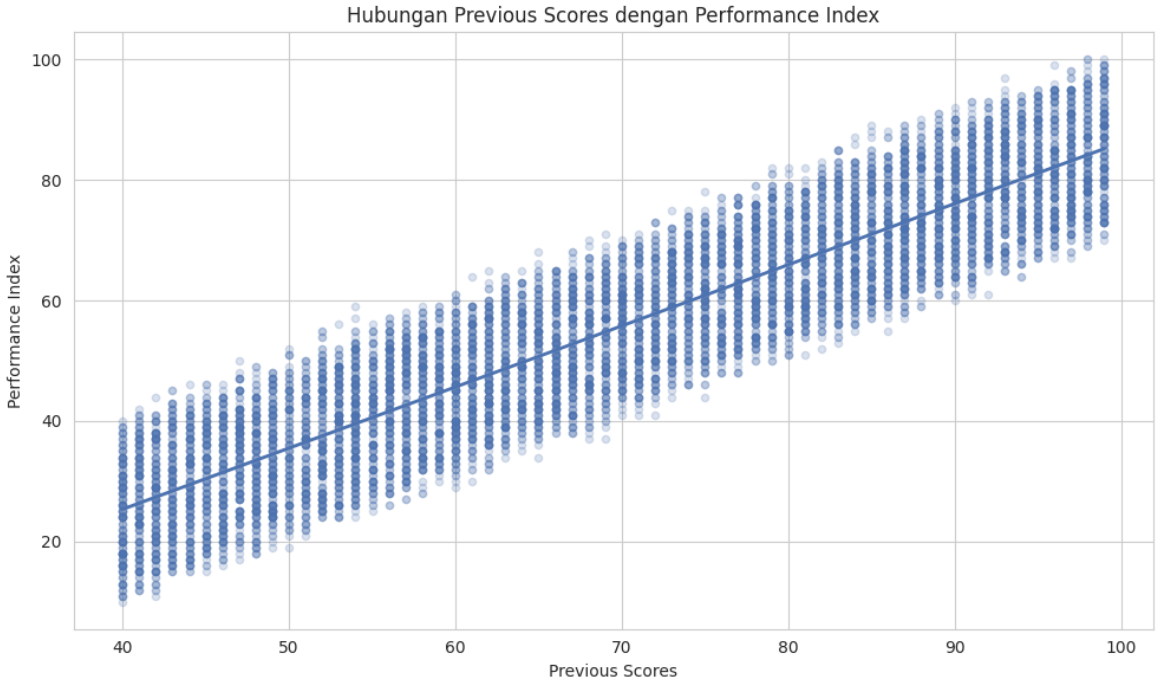
Previous Scores memiliki korelasi paling kuat, diikuti Hours Studied. Sleep Hours dan jumlah latihan soal berkorelasi sangat lemah dengan Performance Index.

5. Tiga Insight Utama dan Hipotesis

Setiap temuan didukung hasil statistik dan visualisasi. Hipotesis berikut merupakan dasar pengujian lanjutan.

Insight 1: Previous Scores paling kuat berkaitan dengan Performance Index

Pertanyaan: seberapa kuat hubungan nilai sebelumnya dengan performa saat ini?



Gambar 3. Hubungan Previous Scores dengan Performance Index (r = 0,915)

Temuan: Previous Scores memiliki korelasi positif **0,915** dengan Performance Index, tertinggi di antara variabel numerik yang dianalisis. Grafik sebar menunjukkan pola yang konsisten: siswa dengan nilai sebelumnya lebih tinggi cenderung memperoleh Performance Index lebih tinggi.

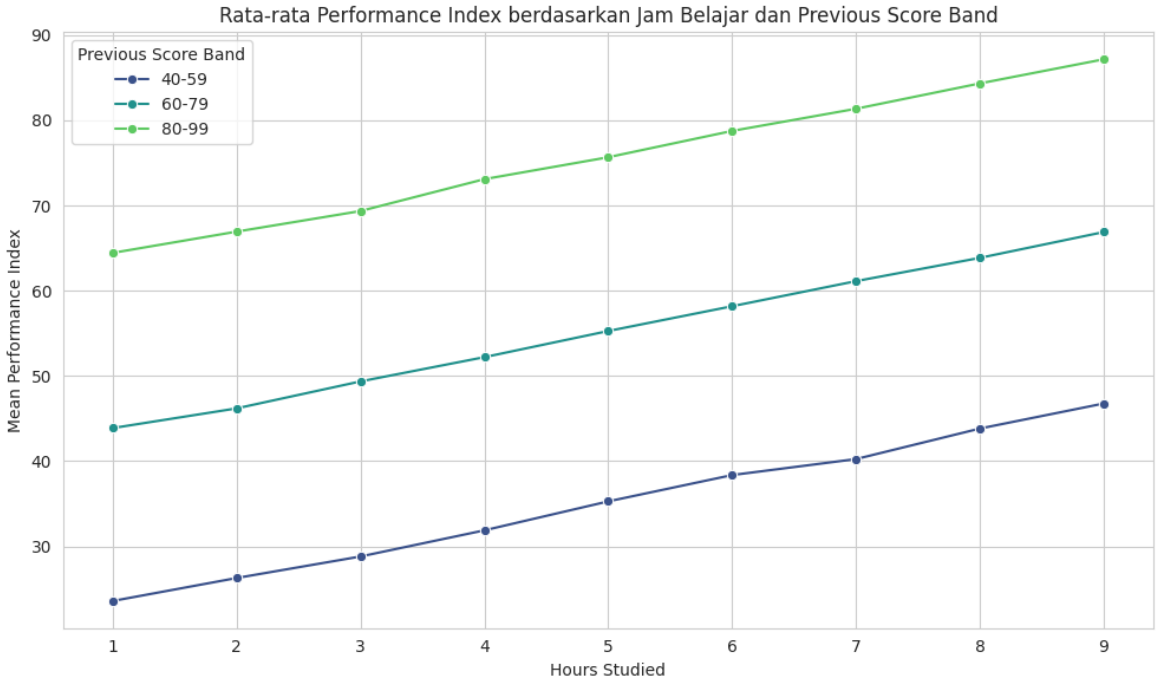
Hipotesis: siswa dengan nilai sebelumnya rendah berpeluang membutuhkan penguatan materi dasar. Previous Scores dapat diuji sebagai dasar penyaringan awal untuk menentukan prioritas remedial.

> Hubungan ini bersifat korelasional; hasil EDA belum membuktikan penyebabnya.

Insight 2: Jam belajar berkaitan dengan performa pada setiap kelompok nilai awal

Pertanyaan: apakah pola hubungan jam belajar dan performa tetap terlihat setelah siswa dikelompokkan menurut Previous Scores?

Previous Scores dikelompokkan menjadi tiga band: 40-59, 60-79, dan 80-99.



Gambar 4. Rata-rata Performance Index berdasarkan jam belajar dan Previous Score Band

Temuan: dalam setiap kelompok Previous Scores, rata-rata Performance Index meningkat seiring bertambahnya Hours Studied. Pola ini menunjukkan bahwa jam belajar layak ditelaah sebagai sasaran program, dengan tetap mempertimbangkan perbedaan nilai awal.

Hipotesis: jadwal belajar yang terstruktur, disertai dukungan akademik sesuai kemampuan awal, berpotensi memperbaiki performa.

> Analisis ini belum mengukur dampak penambahan jam belajar. Hipotesis perlu diuji dengan data dari waktu ke waktu atau eksperimen.

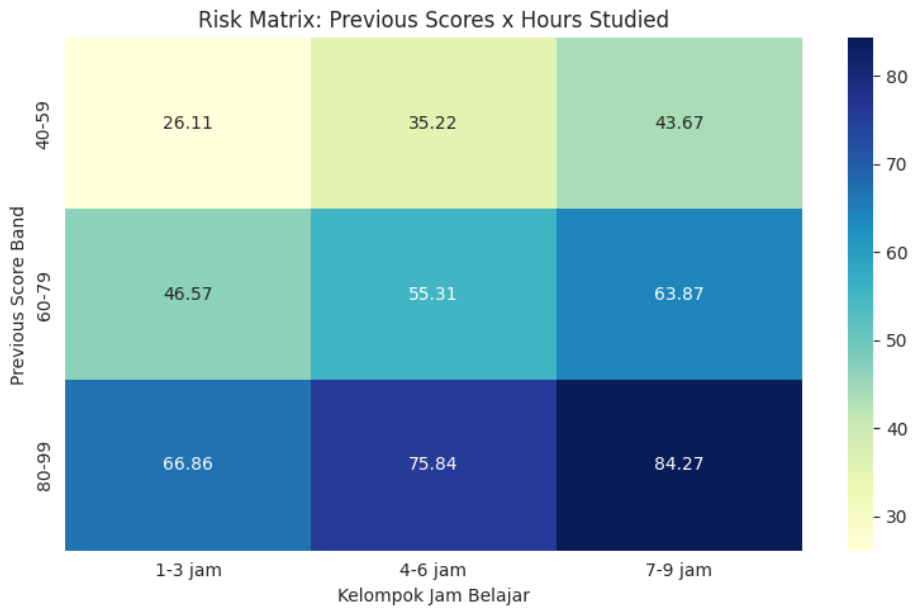
Insight 3: Jam belajar tinggi belum menghapus selisih performa antarkelompok

Pertanyaan: apakah siswa dengan Previous Scores rendah dan jam belajar tinggi mencapai performa kelompok nilai awal menengah?

Hours Studied dikelompokkan menjadi 1-3 jam, 4-6 jam, dan 7-9 jam.

Tabel 6. Rata-rata Performance Index per segmen

Previous Score Band	1-3 jam	4-6 jam	7-9 jam
40-59	26,11	35,22	43,67
60-79	46,57	55,31	63,87
80-99	66,86	75,84	84,27



Gambar 5. Risk matrix: Previous Scores x Hours Studied

Temuan: pada kelompok Previous Scores **40-59**, rata-rata Performance Index naik dari **26,11** pada 1-3 jam belajar menjadi **43,67** pada 7-9 jam: selisih **17,56 poin**. Angka **43,67** masih di bawah kelompok Previous Scores **60-79** yang belajar 1-3 jam (**46,57**).

Hipotesis: bagi kelompok nilai awal rendah, program yang menggabungkan remedial konsep dan pembinaan kebiasaan belajar berpotensi lebih tepat daripada program jam belajar saja. Kelompok nilai awal menengah dengan jam belajar rendah dapat menjadi sasaran dukungan konsistensi belajar.

6. Ringkasan Tiga Insight

Tabel berikut merangkum bukti dan tindak lanjut untuk laporan teknis.

Tabel 7. Ringkasan insight, bukti, dan tindak lanjut

Insight	Bukti	Hipotesis / Tindak Lanjut
Previous Scores paling kuat berkaitan dengan performa	Korelasi Previous Scores dan Performance Index: 0,915	Uji penyaringan awal berdasarkan Previous Scores dan prioritas penguatan materi dasar
Jam belajar berkaitan dengan performa di setiap kelompok nilai awal	Rata-rata Performance Index meningkat seiring jam belajar di tiap kelompok nilai awal	Uji jadwal belajar terstruktur sesuai kelompok nilai awal
Jam belajar tinggi belum menghapus selisih antarkelompok	Kelompok 40-59: selisih 17,56 poin antara 1-3 dan 7-9 jam; nilai akhir masih di bawah kelompok 60-79 dengan 1-3 jam	Uji kombinasi remedial konsep dan pembinaan kebiasaan belajar

7. Analisis Tambahan: Model Prediksi

Linear Regression digunakan untuk memperkirakan Performance Index dari variabel yang tersedia. Target berupa angka kontinu dan pola pada EDA tampak mendekati linear. Koefisien model membantu menjelaskan asosiasi tiap variabel setelah variabel lain diperhitungkan.

Rancangan Evaluasi

- Baris identik dihapus terlebih dahulu, menyisakan **9.873 baris**.
- Data dibagi 80:20 (random state 42): **7.898 baris latih** dan **1.975 baris uji**.

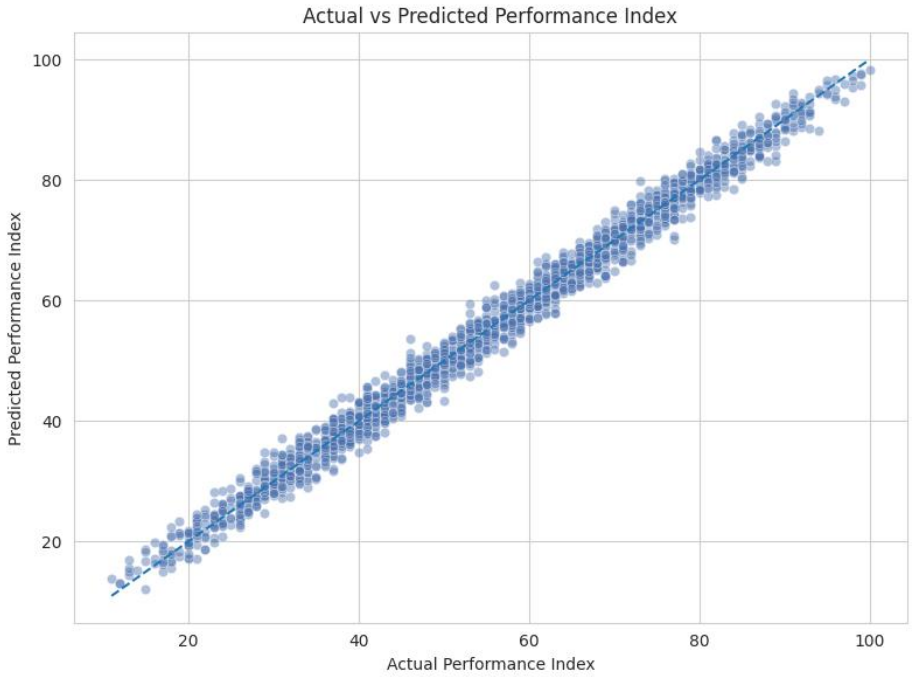
- Extracurricular Activities diubah dengan one-hot encoding (Yes sebagai indikator); variabel numerik digunakan apa adanya.

Tabel 8. Kinerja model pada data uji

Metrik	Nilai
R^2	0,9884
MAE	1,6470
RMSE	2,0751

Tabel 9. Koefisien Linear Regression (diurutkan menurut nilai absolut)

Fitur	Koefisien
Hours Studied	2,851
Previous Scores	1,018
Extracurricular Activities (Yes)	0,574
Sleep Hours	0,472
Sample Question Papers Practiced	0,189



Gambar 6. Actual vs Predicted Performance Index pada data uji

Interpretasi Model

R^2 menunjukkan proporsi variasi target yang dijelaskan model pada data uji; MAE dan RMSE menunjukkan besarnya kesalahan prediksi. Hasil evaluasi berlaku untuk pembagian data yang digunakan dan belum menjamin kinerja pada siswa atau periode lain.

Koefisien menggambarkan asosiasi setelah variabel lain diperhitungkan. Koefisien dan akurasi prediksi tidak membuktikan bahwa perubahan satu variabel akan menyebabkan perubahan nilai siswa.

Prediksi dapat membantu menyusun prioritas peninjauan, dengan keputusan intervensi tetap memerlukan pertimbangan pendidik.

8. Kesimpulan dan Rekomendasi

1. **Previous Scores** menunjukkan hubungan terkuat dengan Performance Index dan dapat digunakan untuk penyaringan awal.
2. **Hours Studied** menunjukkan hubungan positif di setiap kelompok nilai sebelumnya.
3. Kelompok nilai awal rendah dengan jam belajar rendah memiliki rata-rata performa paling rendah. Jam belajar tinggi pada kelompok nilai awal rendah masih belum menyamai rata-rata kelompok nilai awal menengah dengan jam belajar rendah.

Usulan Intervensi

Tabel 10. Usulan intervensi menurut segmen siswa

Segmen	Usulan intervensi
Nilai awal rendah	Penguatan materi dasar dan pembinaan kebiasaan belajar
Nilai awal menengah, jam belajar rendah	Dukungan jadwal dan konsistensi belajar
Nilai awal tinggi, kebiasaan belajar baik	Pemantauan berkala

> Efektivitas program perlu diuji menggunakan data dari beberapa periode atau eksperimen sebelum diterapkan secara luas.

Lampiran

1. Riwayat Block Code

Code Cell 1

```
Code Cell 1

# Library untuk manipulasi data
import os
import io
import textwrap
import warnings
import numpy as np
import pandas as pd

# Library untuk visualisasi
import matplotlib.pyplot as plt
import seaborn as sns

warnings.filterwarnings("ignore")
sns.set_style("whitegrid")

# Folder untuk menyimpan grafik yang nanti dimasukkan ke Technical Report
OUTPUT_DIR = "week4_outputs"
os.makedirs(OUTPUT_DIR, exist_ok=True)

print("Persiapan selesai.")
```

Code Cell 2

```
Code Cell 2

# Upload CSV dari komputer
try:
    from google.colab import files
    uploaded = files.upload()

    csv_name = next(iter(uploaded))
    dataset = pd.read_csv(io.BytesIO(uploaded[csv_name]))
    print(f"Dataset berhasil dibaca: {csv_name}")
except ImportError:
    # Fallback jika notebook dijalankan di Jupyter lokal
    csv_name = input("Masukkan path file CSV: ").strip()
    dataset = pd.read_csv(csv_name)

print("Ukuran dataset:", dataset.shape)
dataset.head()
```

Code Cell 3

```
Code Cell 3

print("INFO DATASET")
dataset.info()

print("\n5 BARIS PERTAMA")
display(dataset.head())

print("\n5 BARIS TERAKHIR")
display(dataset.tail())
```

Code Cell 4

```
Code Cell 4

# Pemeriksaan kualitas data
missing_summary = dataset.isna().sum().to_frame("Missing")
missing_summary["Missing (%)"] = (missing_summary["Missing"] / len(dataset) * 100).round(2)

duplicate_count = dataset.duplicated().sum()

print("NILAI KOSONG")
display(missing_summary)

print(f"Jumlah exact duplicate rows: {duplicate_count}")
print(f"Persentase exact duplicate : {duplicate_count / len(dataset) * 100:.2f}%")

# Validasi rentang berdasarkan definisi fitur pada dataset
range_checks = {
    "Hours Studied": dataset["Hours Studied"].between(1, 9).all(),
    "Previous Scores": dataset["Previous Scores"].between(40, 99).all(),
    "Sleep Hours": dataset["Sleep Hours"].between(4, 9).all(),
    "Sample Question Papers Practiced": dataset["Sample Question Papers Practiced"].between(0, 9).all(),
    "Performance Index": dataset["Performance Index"].between(10, 100).all()
}

print("\nRANGE CHECK")
for col, status in range_checks.items():
    print(f"{col:35s}: {'OK' if status else 'PERLU REVIEW'}")

print("\nKeputusan analisis:")
print("- EDA menggunakan seluruh catatan yang tersedia.")
print("- Baris identik belum dapat dipastikan sebagai kesalahan pencatatan tanpa identitas siswa.")
print("- Evaluasi model menghapus baris identik sebelum membagi data latih dan uji.")
```

Code Cell 5

```
Code Cell 5

# Kolom numerik
numeric_cols = dataset.select_dtypes(include=np.number).columns.tolist()

numeric_profile = pd.DataFrame({
    "Mean": dataset[numeric_cols].mean(),
    "Median": dataset[numeric_cols].median(),
    "Mode": [dataset[col].mode().iloc[0] for col in numeric_cols],
    "Std Dev": dataset[numeric_cols].std(),
    "Minimum": dataset[numeric_cols].min(),
    "Maximum": dataset[numeric_cols].max()
}).round(2)

print("STATISTICAL PROFILING - NUMERIK")
display(numeric_profile)
```

Link : https://colab.research.google.com/drive/1X79KS47k_9NTo66P4OzwcAYXWkRZ7Mqz?usp=sharing

Code Cell 6

```
Code Cell 6

# Kolom kategorikal
categorical_cols = dataset.select_dtypes(include="object").columns.tolist()

categorical_rows = []
for col in categorical_cols:
    vc = dataset[col].value_counts()
    categorical_rows.append({
        "Column": col,
        "Unique Categories": dataset[col].nunique(),
        "Mode": dataset[col].mode().iloc[0],
        "Mode Frequency": int(vc.iloc[0]),
        "Mode Proportion (%)": round(vc.iloc[0] / len(dataset) * 100, 2)
    })

categorical_profile = pd.DataFrame(categorical_rows)

print("STATISTICAL PROFILING - KATEGORIKAL")
display(categorical_profile)

print("\nDistribusi Extracurricular Activities:")
display(
    dataset["Extracurricular Activities"]
    .value_counts()
    .rename_axis("Category")
    .to_frame("Count")
    .assign(Proportion=lambda x: (x["Count"] / len(dataset) * 100).round(2))
)
```

Code Cell 7

```
Code Cell 7

# Ringkasan statistik
perf_mean = dataset["Performance Index"].mean()
perf_median = dataset["Performance Index"].median()
perf_std = dataset["Performance Index"].std()

prev_mean = dataset["Previous Scores"].mean()
hours_mean = dataset["Hours Studied"].mean()
sleep_mean = dataset["Sleep Hours"].mean()
paper_mean = dataset["Sample Question Papers Practiced"].mean()

print("RINGKASAN STATISTIK")
print(
    f"1. Performance Index: rata-rata {perf_mean:.2f}, median {perf_median:.2f}, "
    f"simpangan baku {perf_std:.2f}. Sebaran nilai antarsiswa cukup besar."
)
print(
    f"2. Previous Scores: rata-rata {prev_mean:.2f}. Hubungannya dengan Performance Index "
    "ditelaah pada analisis korelasi."
)
print(
    f"3. Hours Studied: rata-rata {hours_mean:.2f} jam; Sleep Hours: {sleep_mean:.2f} jam; "
    f"latihan soal: {paper_mean:.2f}. Hubungan masing-masing dengan target diperiksa berikutnya."
)
print(
    "4. Extracurricular Activities: kategori Yes dan No memiliki jumlah yang hampir seimbang."
)
```

Code Cell 8

```
Code Cell 8

plt.figure(figsize=(10, 6))
sns.histplot(dataset["Performance Index"], bins=20, kde=True, color="#4C72B0")
plt.axvline(dataset["Performance Index"].mean(), linestyle="--", label=f"Mean = {dataset['Performance
    Index'].mean():.2f}")
plt.axvline(dataset["Performance Index"].median(), linestyle=":", label=f"Median = {dataset['Performance
    Index'].median():.2f}")
plt.title("Distribusi Performance Index Siswa")
plt.xlabel("Performance Index")
plt.ylabel("Frekuensi")
plt.legend()
plt.tight_layout()

target_plot = os.path.join(OUTPUT_DIR, "01_distribution_performance.png")
plt.savefig(target_plot, dpi=180, bbox_inches="tight")
plt.show()
```

Code Cell 9

```
Code Cell 9

corr_matrix = dataset[numeric_cols].corr()

plt.figure(figsize=(9, 7))
sns.heatmap(corr_matrix, annot=True, fmt=".2f", cmap="coolwarm", vmin=-1, vmax=1)
plt.title("Correlation Heatmap - Student Performance")
plt.xlabel("Variabel Numerik")
plt.ylabel("Variabel Numerik")
plt.tight_layout()

corr_plot = os.path.join(OUTPUT_DIR, "02_correlation_heatmap.png")
plt.savefig(corr_plot, dpi=180, bbox_inches="tight")
plt.show()

target_corr = corr_matrix["Performance Index"].sort_values(ascending=False)
print("Korelasi terhadap Performance Index:")
display(target_corr.to_frame("Correlation"))
```

Code Cell 10

```
Code Cell 10

prev_corr = dataset["Previous Scores"].corr(dataset["Performance Index"])

plt.figure(figsize=(10, 6))
sns.regplot(
    data=dataset,
    x="Previous Scores",
    y="Performance Index",
    scatter_kws={"alpha": 0.20, "s": 20},
    line_kws={"linewidth": 2},
    color="#4C72B0"
)
plt.title("Hubungan Previous Scores dengan Performance Index")
plt.xlabel("Previous Scores")
plt.ylabel("Performance Index")
plt.tight_layout()

prev_plot = os.path.join(OUTPUT_DIR, "03_previous_scores_vs_performance.png")
plt.savefig(prev_plot, dpi=180, bbox_inches="tight")
plt.show()

print(f"Correlation Previous Scores vs Performance Index = {prev_corr:.3f}")
```

4

Code Cell 11

```
Code Cell 11

# Membuat band skor sebelumnya untuk analisis yang lebih mudah dibaca
dataset_eda = dataset.copy()
dataset_eda["Previous Score Band"] = pd.cut(
    dataset_eda["Previous Scores"],
    bins=[39, 59, 79, 99],
    labels=["40-59", "60-79", "80-99"],
    include_lowest=True
)

mean_by_hours = (
    dataset_eda
    .groupby(["Previous Score Band", "Hours Studied"], observed=False)["Performance Index"]
    .mean()
    .reset_index()
)

plt.figure(figsize=(10, 6))
sns.lineplot(
    data=mean_by_hours,
    x="Hours Studied",
    y="Performance Index",
    hue="Previous Score Band",
    marker="o",
    palette="viridis"
)
plt.title("Rata-rata Performance Index berdasarkan Jam Belajar dan Previous Score Band")
plt.xlabel("Hours Studied")
plt.ylabel("Mean Performance Index")
plt.legend(title="Previous Score Band")
plt.tight_layout()

hours_plot = os.path.join(OUTPUT_DIR, "04_hours_by_previous_band.png")
plt.savefig(hours_plot, dpi=180, bbox_inches="tight")
plt.show()

display(mean_by_hours.head(12))
```

4

Code Cell 12

```
Code Cell 12

dataset_eda["Hours Group"] = pd.cut(
    dataset_eda["Hours Studied"],
    bins=[0, 3, 6, 9],
    labels=["1-3 jam", "4-6 jam", "7-9 jam"],
    include_lowest=True
)

risk_matrix = dataset_eda.pivot_table(
    values="Performance Index",
    index="Previous Score Band",
    columns="Hours Group",
    aggfunc="mean",
    observed=False
).round(2)

print("Rata-rata Performance Index per segmen:")
display(risk_matrix)

plt.figure(figsize=(8, 5))
sns.heatmap(risk_matrix, annot=True, fmt=".2f", cmap="YlGnBu")
plt.title("Risk Matrix: Previous Scores x Hours Studied")
plt.xlabel("Kelompok Jam Belajar")
plt.ylabel("Previous Score Band")
plt.tight_layout()

risk_plot = os.path.join(OUTPUT_DIR, "05_risk_matrix.png")
plt.savefig(risk_plot, dpi=180, bbox_inches="tight")
plt.show()

low_low = risk_matrix.loc["40-59", "1-3 jam"]
low_high = risk_matrix.loc["40-59", "7-9 jam"]
mid_low = risk_matrix.loc["60-79", "1-3 jam"]
high_high = risk_matrix.loc["80-99", "7-9 jam"]

print(f"Nilai awal rendah, 1-3 jam : {low_low:.2f}")
print(f"Nilai awal rendah, 7-9 jam : {low_high:.2f}")
print(f"Nilai awal menengah, 1-3 jam: {mid_low:.2f}")
print(f"Nilai awal tinggi, 7-9 jam : {high_high:.2f}")
print(f"Selisih kelompok nilai awal rendah (1-3 dan 7-9 jam): {low_high - low_low:.2f} poin")
```

Code Cell 13

```
Code Cell 13

insight_summary = pd.DataFrame({
    "Insight": [
        "Previous Scores paling kuat berkaitan dengan performa",
        "Jam belajar berkaitan dengan performa di setiap kelompok nilai awal",
        "Jam belajar tinggi belum menghapus selisih antarkelompok"
    ],
    "Bukti": [
        f"Korelasi Previous Scores dan Performance Index: {prev_corr:.3f}",
        "Rata-rata Performance Index meningkat seiring jam belajar di tiap kelompok nilai awal",
        f"Kelompok 40-59: selisih {low_high - low_low:.2f} poin antara 1-3 dan 7-9 jam; nilai akhir masih
     di bawah kelompok 60-79 dengan 1-3 jam"
    ],
    "Hipotesis / Tindak Lanjut": [
        "Uji penyaringan awal berdasarkan Previous Scores dan prioritas penguatan materi dasar",
        "Uji jadwal belajar terstruktur sesuai kelompok nilai awal",
        "Uji kombinasi remedial konsep dan pembinaan kebiasaan belajar"
    ]
})

display(insight_summary)
```

Code Cell 14

```
Code Cell 14

from sklearn.model_selection import train_test_split
from sklearn.compose import ColumnTransformer
from sklearn.preprocessing import OneHotEncoder
from sklearn.pipeline import Pipeline
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score

# Untuk evaluasi model, exact duplicate dihapus agar tidak mudah muncul di train dan test sekaligus
dataset_model = dataset.drop_duplicates().copy()

X = dataset_model.drop(columns="Performance Index")
y = dataset_model["Performance Index"]

categorical_features = ["Extracurricular Activities"]
numeric_features = [col for col in X.columns if col not in categorical_features]

preprocessor = ColumnTransformer(
    transformers=[
        ("num", "passthrough", numeric_features),
        ("cat", OneHotEncoder(drop="first", handle_unknown="ignore"), categorical_features)
    ]
)

model = Pipeline(steps=[
    ("preprocessor", preprocessor),
    ("regressor", LinearRegression())
])

X_train, X_test, y_train, y_test = train_test_split(
    X, y,
    test_size=0.20,
    random_state=42
)

model.fit(X_train, y_train)
y_pred = model.predict(X_test)

r2 = r2_score(y_test, y_pred)
mae = mean_absolute_error(y_test, y_pred)
rmse = np.sqrt(mean_squared_error(y_test, y_pred))

print("MODEL PERFORMANCE")
print(f"Data model setelah drop exact duplicate: {len(dataset_model):,} rows")
print(f"Train rows: {len(X_train):,}")
print(f"Test rows : {len(X_test):,}")
print(f"R²        : {r2:.4f}")
print(f"MAE       : {mae:.4f}")
print(f"RMSE      : {rmse:.4f}")
```

4

Code Cell 15

```
Code Cell 15

# Mengambil koefisien model agar hasil prediksi tetap interpretable
ohe = model.named_steps["preprocessor"].named_transformers_["cat"]
encoded_names = ohe.get_feature_names_out(categorical_features).tolist()
feature_names = numeric_features + encoded_names

coefficients = model.named_steps["regressor"].coef_

coef_df = pd.DataFrame({
    "Feature": feature_names,
    "Coefficient": coefficients
}).sort_values("Coefficient", key=np.abs, ascending=False)

print("KOEFISIEN LINEAR REGRESSION")
display(coef_df.round(4))

print("\nKoefisien model:")
for _, row in coef_df.iterrows():
    print(f"- {row['Feature']}: koefisien {row['Coefficient']:.3f}")
```

Code Cell 16

```
Code Cell 16

# Visual validasi model: Actual vs Predicted
plt.figure(figsize=(8, 6))
sns.scatterplot(x=y_test, y=y_pred, alpha=0.45, color="#4C72B0")
min_val = min(y_test.min(), y_pred.min())
max_val = max(y_test.max(), y_pred.max())
plt.plot([min_val, max_val], [min_val, max_val], linestyle="--")
plt.title("Actual vs Predicted Performance Index")
plt.xlabel("Actual Performance Index")
plt.ylabel("Predicted Performance Index")
plt.tight_layout()

model_plot = os.path.join(OUTPUT_DIR, "06_actual_vs_predicted.png")
plt.savefig(model_plot, dpi=180, bbox_inches="tight")
plt.show()
```